

WDDA FS 2026: Leitfaden für Aufgabenserie 7

2026-05-20

1 Einleitung

Dieser Leitfaden bietet detaillierte Erklärungen für die Übungen in WDDA FS 2026 Aufgabenserie/Übungsblatt 7. Die Serie konzentriert sich auf die **Inferenz in Regressionsmodellen** – also auf Konfidenzintervalle, Signifikanztests und Prognoseintervalle. Wir lernen, wie zuverlässig die geschätzten Koeffizienten und Vorhersagen sind und wie Hypothesen über Modellparameter getestet werden.

2 Aufgabe 1: Advertising – Konfidenzintervalle und Bootstrap

Aufgabenstellung: Analysieren Sie den Werbedatensatz und vergleichen Sie klassische und Bootstrap-Konfidenzintervalle für die Koeffizienten der einfachen und multiplen Regression. Untersuchen Sie die Signifikanz der Prädiktoren und führen Sie einen Modellvergleich durch.

2.1 Schritt 1: Daten einlesen und einfaches Modell schätzen (a)

```
Advertising <- read_excel("../data/WDDA_07.xlsx", sheet = "Advertising")
head(Advertising)
```

```
## # A tibble: 6 x 4
##   TV radio newspaper sales
##   <dbl> <dbl>   <dbl> <dbl>
## 1 230.   37.8    69.2  22.1
## 2  44.5   39.3    45.1  10.4
## 3  17.2   45.9    69.3   9.3
## 4 152.   41.3    58.5  18.5
## 5 181.   10.8    58.4  12.9
## 6   8.7   48.9     75   7.2
```

```
mod_tv <- lm(sales ~ TV, data = Advertising)
summary(mod_tv)
```

```
##
## Call:
## lm(formula = sales ~ TV, data = Advertising)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8.3860 -1.9545 -0.1913  2.0671  7.2124
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  7.032594   0.457843   15.36  <2e-16 ***
## TV           0.047537   0.002691   17.67  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 3.259 on 198 degrees of freedom
## Multiple R-squared:  0.6119, Adjusted R-squared:  0.6099
## F-statistic: 312.1 on 1 and 198 DF,  p-value: < 2.2e-16
```

Interpretation:

- **Intercept** ($\beta_0 \approx 7.03$): erwartete Sales bei TV = 0.
- **TV-Koeffizient** ($\beta_1 \approx 0.048$): pro 1\$ TV-Ausgaben steigen die Sales im Durchschnitt um ca. 0.048 Einheiten.
- Beide Koeffizienten sind hoch signifikant ($p < 0.001$).

2.2 Schritt 2: Klassisches Konfidenzintervall (b)

```
confint(mod_tv)
```

```
##                2.5 %      97.5 %
## (Intercept) 6.12971927 7.93546783
## TV          0.04223072 0.05284256
```

Interpretation: Das 95%-Konfidenzintervall für den TV-Koeffizienten liegt etwa zwischen 0.042 und 0.053 – d.h. wir sind zu 95% sicher, dass der wahre Effekt von TV-Ausgaben auf Sales in diesem Bereich liegt.

2.3 Schritt 3: Bootstrap-Konfidenzintervall (c)

```
set.seed(123)
simcoef <- do(5000) * coef(lm(sales ~ TV, data = resample(Advertising)))

CI_intercept <- quantile(simcoef$Intercept, c(0.025, 0.975))
CI_tv <- quantile(simcoef$TV, c(0.025, 0.975))

cat("Bootstrap 95%-CI für Intercept:", round(CI_intercept, 3), "\n")
```

```
## Bootstrap 95%-CI für Intercept: 6.391 7.697
```

```
cat("Bootstrap 95%-CI für TV:      ", round(CI_tv, 3), "\n")
```


```
## Bootstrap 95%-CI für TV:      0.042 0.053
```

Vergleich: Die Bootstrap-Intervalle stimmen sehr gut mit den klassischen Intervallen überein. Das ist erwartet, wenn die klassischen Annahmen (Normalverteilung der Residuen, konstante Varianz) hinreichend gut erfüllt sind.

2.4 Schritt 4: Visualisierung der Bootstrap-Verteilung (d)

```
par(mfrow = c(1, 2))
hist(simcoef$TV, main = "Bootstrap-Verteilung TV", xlab = "TV-Koeffizient",
     col = "lightgray", border = "white", breaks = 25)
abline(v = quantile(simcoef$TV, c(0.025, 0.975)), col = "red", lty = 2, lwd = 2)

hist(simcoef$Intercept, main = "Bootstrap-Verteilung Intercept", xlab = "Intercept",
     col = "lightgray", border = "white", breaks = 25)
abline(v = quantile(simcoef$Intercept, c(0.025, 0.975)), col = "red", lty = 2, lwd = 2)
```



```
par(mfrow = c(1, 1))
```

Bewertung: Beide Verteilungen sind annähernd glockenförmig (zentraler Grenzwertsatz). Die roten Linien markieren die 95%-Konfidenzgrenzen.

2.5 Schritt 5: Multiple Regression (e)

```
mod_full <- lm(sales ~ TV + radio + newspaper, data = Advertising)
summary(mod_full)
```

```
##
## Call:
## lm(formula = sales ~ TV + radio + newspaper, data = Advertising)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8.8277 -0.8908  0.2418  1.1893  2.8292
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.938889   0.311908   9.422  <2e-16 ***
## TV           0.045765   0.001395  32.809  <2e-16 ***
## radio        0.188530   0.008611  21.893  <2e-16 ***
## newspaper    -0.001037   0.005871  -0.177    0.86
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.686 on 196 degrees of freedom
## Multiple R-squared:  0.8972, Adjusted R-squared:  0.8956
## F-statistic: 570.3 on 3 and 196 DF,  p-value: < 2.2e-16
```

Interpretation:

- TV und radio sind hoch signifikant ($p < 0.001$).
- newspaper ist **nicht signifikant** ($p \approx 0.86$) – der Effekt ist statistisch nicht von Null unterscheidbar.

- Der F-Test ($p < 2.2 \cdot 10^{-16}$) zeigt: insgesamt erklärt das Modell die Sales signifikant.

2.6 Schritt 6: Modellvergleich mittels ANOVA F-Test (f)

```
mod_red <- lm(sales ~ TV + radio, data = Advertising)
anova(mod_red, mod_full)
```

```
## Analysis of Variance Table
##
## Model 1: sales ~ TV + radio
## Model 2: sales ~ TV + radio + newspaper
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1     197 556.91
## 2     196 556.83   1  0.088717 0.0312 0.8599
```

Interpretation:

- Der F-Test vergleicht das reduzierte Modell (TV + radio) mit dem vollen Modell.
- $p > 0.05$ bedeutet: **newspaper** liefert keinen signifikanten zusätzlichen Erklärungsbeitrag.
- **Fazit:** Wir können **newspaper** aus dem Modell entfernen, ohne wesentlich Erklärungskraft zu verlieren.

2.7 Schritt 7: Prognose mit Konfidenz- und Prognoseintervall (g)

```
neue_werte <- data.frame(TV = 200, radio = 30)

ci_mean <- predict(mod_red, newdata = neue_werte, interval = "confidence")
pi_obs <- predict(mod_red, newdata = neue_werte, interval = "prediction")

cat("Konfidenzintervall für mittlere Sales:\n")
```

```
## Konfidenzintervall für mittlere Sales:
```

```
print(ci_mean)
```

```
##           fit          lwr          upr
## 1 17.71189 17.41904 18.00474
```

```
cat("\nPrognoseintervall für einzelne Beobachtung:\n")
```

```
##
## Prognoseintervall für einzelne Beobachtung:
```

```
print(pi_obs)
```

```
##           fit          lwr          upr
## 1 17.71189 14.38321 21.04057
```

Interpretation:

- Das **Konfidenzintervall** (lwr, upr in **ci_mean**) bezieht sich auf den **Erwartungswert** der Sales bei den vorgegebenen Werten – d.h. den Mittelwert über viele hypothetische Beobachtungen.
- Das **Prognoseintervall** ist breiter, da es zusätzlich die Streuung **einzelner** Beobachtungen um die Regressionsfläche berücksichtigt.

3 Aufgabe 2: Diamond Rings – Inferenz und Prognose

Aufgabenstellung: Untersuchen Sie für den Diamond-Rings-Datensatz die Zusammenhänge zwischen Gewicht und Preis. Berechnen Sie Konfidenz- und Prognoseintervalle, und testen Sie die Signifikanz der Stei-

gung.

3.1 Schritt 1: Daten und Modell (a)

```
diamonds <- read_excel("../data/WDDA_07.xlsx", sheet = "Diamonds Rings")
names(diamonds) <- c("weight", "price")
head(diamonds)
```

```
## # A tibble: 6 x 2
##   weight price
##   <dbl> <dbl>
## 1  0.17  355
## 2  0.16  328
## 3  0.17  350
## 4  0.18  325
## 5  0.25  642
## 6  0.16  342
```

```
mod_dr <- lm(price ~ weight, data = diamonds)
summary(mod_dr)
```

```
##
## Call:
## lm(formula = price ~ weight, data = diamonds)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -85.159 -21.448  -0.869  18.972  79.370
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -259.63      17.32  -14.99  <2e-16 ***
## weight       3721.02      81.79   45.50  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 31.84 on 46 degrees of freedom
## Multiple R-squared:  0.9783, Adjusted R-squared:  0.9778
## F-statistic: 2070 on 1 and 46 DF,  p-value: < 2.2e-16
```

Interpretation:

- **Steigung** (≈ 3721): pro 1 Karat Mehrgewicht steigt der Preis im Durchschnitt um etwa 3721 SGD.
- Der t-Wert für **weight** ist gross, p extrem klein – der Effekt ist hoch signifikant.

3.2 Schritt 2: Konfidenzintervall für die Steigung (b)

```
confint(mod_dr)
```

```
##              2.5 %    97.5 %
## (Intercept) -294.487 -224.7649
## weight      3556.398 3885.6513
```

Interpretation: Das 95%-Konfidenzintervall für die Steigung ist eng und liegt deutlich oberhalb von Null – der Zusammenhang ist statistisch klar gesichert.

3.3 Schritt 3: Bootstrap-Konfidenzintervall (c)

```
set.seed(42)
simcoef_dr <- do(5000) * coef(lm(price ~ weight, data = resample(diamonds)))

CI_weight <- quantile(simcoef_dr$weight, c(0.025, 0.975))
cat("Bootstrap 95%-CI für Steigung (weight):", round(CI_weight, 1), "\n")
```

Bootstrap 95%-CI für Steigung (weight): 3570.4 3870.6

Vergleich: Bootstrap- und klassisches Intervall sollten in dieser Größenordnung sehr ähnlich sein.

3.4 Schritt 4: Prognose für ein neues Ring (d)

```
neu <- data.frame(weight = 0.25)

ci_mean <- predict(mod_dr, newdata = neu, interval = "confidence")
pi_obs <- predict(mod_dr, newdata = neu, interval = "prediction")

cat("Mittlerer erwarteter Preis (95%-CI):\n")
```

Mittlerer erwarteter Preis (95%-CI):

```
print(ci_mean)
```

```
##          fit          lwr          upr
## 1 670.6303 658.6925 682.5681
```

```
cat("\nPrognose-Intervall für einzelnen Ring (95%-PI):\n")
```

##

Prognose-Intervall für einzelnen Ring (95%-PI):

```
print(pi_obs)
```

```
##          fit          lwr          upr
## 1 670.6303 605.4364 735.8242
```


Interpretation: Das Prognoseintervall ist breiter als das Konfidenzintervall, weil es auch die individuelle Streuung um die Regressionsgerade berücksichtigt.

3.5 Schritt 5: Visualisierung mit Intervallen (e)

```
grid <- data.frame(weight = seq(min(diamonds$weight), max(diamonds$weight), length.out = 100))
ci <- predict(mod_dr, newdata = grid, interval = "confidence")
pi <- predict(mod_dr, newdata = grid, interval = "prediction")

plot(diamonds$weight, diamonds$price, pch = 16, col = "gray50",
     xlab = "Weight (carats)", ylab = "Price (SGD)",
     main = "Regression mit 95%-CI und PI")
lines(grid$weight, ci[, "fit"], col = "blue", lwd = 2)
lines(grid$weight, ci[, "lwr"], col = "blue", lty = 2)
lines(grid$weight, ci[, "upr"], col = "blue", lty = 2)
lines(grid$weight, pi[, "lwr"], col = "red", lty = 3)
lines(grid$weight, pi[, "upr"], col = "red", lty = 3)
legend("topleft", legend = c("Fit", "95%-CI", "95%-PI"),
     col = c("blue", "blue", "red"), lty = c(1, 2, 3), lwd = c(2, 1, 1))
```

Regression mit 95%-CI und PI



Bewertung: Das PI-Band (rot) ist deutlich breiter als das CI-Band (blau). Beide sind in der Mitte der Daten am engsten und werden zu den Rändern hin breiter.

4 Aufgabe 3: SAT – Multiple Regression und F-Test

Aufgabenstellung: Untersuchen Sie für den SAT-Datensatz, welche Bildungsvariablen den durchschnittlichen SAT-Score eines Bundesstaates am besten erklären. Führen Sie Modellvergleiche mittels F-Test durch.

4.1 Schritt 1: Daten einlesen und erkunden (a)

```
sat <- read_excel("../data/WDDA_07.xlsx", sheet = "SAT")
head(sat)
```

```
## # A tibble: 6 x 8
##   State      expend ratio salary  frac verbal  math  sat
##   <chr>      <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Alabama      4.40  17.2  31.1     8   491   538  1029
## 2 Alaska       8.96  17.6  48.0    47   445   489   934
## 3 Arizona      4.78  19.3  32.2    27   448   496   944
## 4 Arkansas     4.46  17.1  28.9     6   482   523  1005
## 5 California   4.99  24    41.1    45   417   485   902
## 6 Colorado     5.44  18.4  34.6    29   462   518   980
```

```
summary(sat[, c("expend", "ratio", "salary", "frac", "sat")])
```

```
##      expend      ratio      salary      frac
##  Min.   :3.656   Min.   :13.80   Min.   :25.99   Min.    : 4.00
##  1st Qu.:4.882   1st Qu.:15.22   1st Qu.:30.98   1st Qu.: 9.00
##  Median :5.768   Median :16.60   Median :33.29   Median :28.00
##  Mean   :5.905   Mean   :16.86   Mean   :34.83   Mean   :35.24
```

```
## 3rd Qu.:6.434 3rd Qu.:17.57 3rd Qu.:38.55 3rd Qu.:63.00
## Max. :9.774 Max. :24.30 Max. :50.05 Max. :81.00
## sat
## Min. : 844.0
## 1st Qu.: 897.2
## Median : 945.5
## Mean : 965.9
## 3rd Qu.:1032.0
## Max. :1107.0
```

Beschreibung:

- **expend**: Bildungsausgaben pro Schüler (in 1000\$)
- **ratio**: Schüler-Lehrer-Verhältnis
- **salary**: durchschnittliches Lehrergehalt (in 1000\$)
- **frac**: Anteil Schüler, die den SAT ablegen (in %)
- **sat**: durchschnittlicher SAT-Score

4.2 Schritt 2: Einfaches Modell (b)

```
mod1 <- lm(sat ~ expend, data = sat)
summary(mod1)
```

```
##
## Call:
## lm(formula = sat ~ expend, data = sat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -145.074  -46.821    4.087   40.034  128.489
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1089.294     44.390   24.539  < 2e-16 ***
## expend       -20.892      7.328   -2.851  0.00641 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 69.91 on 48 degrees of freedom
## Multiple R-squared:  0.1448, Adjusted R-squared:  0.127
## F-statistic: 8.128 on 1 and 48 DF, p-value: 0.006408
```

Überraschung: Die Steigung von **expend** ist **negativ**! Höhere Bildungsausgaben gehen mit niedrigeren SAT-Scores einher? Das wirkt paradox – Hinweis auf eine Confounding-Variable.

4.3 Schritt 3: Multiple Regression (c)

```
mod2 <- lm(sat ~ expend + ratio + salary + frac, data = sat)
summary(mod2)
```

```
##
## Call:
## lm(formula = sat ~ expend + ratio + salary + frac, data = sat)
##
## Residuals:
```



```
##      Min      1Q  Median      3Q      Max
## -90.531 -20.855  -1.746  15.979  66.571
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1045.9715    52.8698  19.784 < 2e-16 ***
## expend      4.4626     10.5465   0.423  0.674
## ratio      -3.6242     3.2154  -1.127  0.266
## salary      1.6379     2.3872   0.686  0.496
## frac       -2.9045     0.2313 -12.559 2.61e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 32.7 on 45 degrees of freedom
## Multiple R-squared:  0.8246, Adjusted R-squared:  0.809
## F-statistic: 52.88 on 4 and 45 DF,  p-value: < 2.2e-16
```

Interpretation:

- Nach Kontrolle für `frac` (Anteil teilnehmender Schüler) **kehrt sich das Vorzeichen** vieler Koeffizienten um.
- `frac` ist hoch signifikant negativ: Bundesstaaten, in denen mehr Schüler den SAT ablegen, haben niedrigere Durchschnitts-Scores (Selbstselektion).
- `expend` und `salary` haben jetzt positive Vorzeichen – der wahre Effekt zusätzlicher Ressourcen ist also positiv, sobald wir den Selektionseffekt kontrollieren.

4.4 Schritt 4: F-Test des Gesamtmodells (d)

```
f <- summary(mod2)$fstatistic
cat("F-Statistik:", round(f["value"], 2),
    " (df1 =", f["numdf"], ", df2 =", f["dendf"], ")\n")
```

```
## F-Statistik: 52.88 (df1 = 4 , df2 = 45 )
```

Interpretation: Der F-Test prüft die globale Nullhypothese, dass **alle** Steigungen Null sind. Ein hoher F-Wert mit kleinem p verwirft diese Hypothese – mindestens ein Prädiktor erklärt signifikant Varianz.

4.5 Schritt 5: ANOVA-Vergleich geschachtelter Modelle (e)

```
mod_klein <- lm(sat ~ frac, data = sat)
mod_gross <- lm(sat ~ expend + ratio + salary + frac, data = sat)
anova(mod_klein, mod_gross)
```

```
## Analysis of Variance Table
##
## Model 1: sat ~ frac
## Model 2: sat ~ expend + ratio + salary + frac
##   Res.Df  RSS Df Sum of Sq    F Pr(>F)
## 1      48 58433
## 2      45 48124  3    10309 3.2133 0.03165 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interpretation:

- Vergleich des reduzierten Modells (nur `frac`) mit dem vollen Modell.

- Ein signifikanter p -Wert würde bedeuten, dass die zusätzlichen Prädiktoren gemeinsam signifikant zur Erklärung beitragen.
- Falls $p > 0.05$: Die zusätzlichen Variablen liefern keinen signifikanten Mehrgewinn – **frac** allein erklärt den Grossteil der Variation.

4.6 Schritt 6: Prognose für einen hypothetischen Bundesstaat (f)

```
hypothetisch <- data.frame(expend = 6, ratio = 16, salary = 35, frac = 30)
pred <- predict(mod_gross, newdata = hypothetisch, interval = "prediction")
print(pred)
```

```
##          fit          lwr          upr
## 1 984.9521 918.1638 1051.74
```

Interpretation: Erwarteter SAT-Score plus 95%-Prognoseintervall für einen Bundesstaat mit den angegebenen Charakteristika.

5 Zusammenfassung

Diese Aufgabenserie hat gezeigt:

1. **Klassische und Bootstrap-Konfidenzintervalle** liefern bei erfüllten Modellannahmen sehr ähnliche Ergebnisse. Bootstrap ist robuster, wenn Annahmen verletzt sind.
2. **t-Tests** prüfen einzelne Koeffizienten, **F-Tests** prüfen das Gesamtmodell oder Modellvergleiche.
3. **Konfidenz- vs. Prognoseintervalle**: das CI bezieht sich auf den Erwartungswert, das PI auf eine einzelne neue Beobachtung – das PI ist immer breiter.
4. **Multiple Regression** ermöglicht es, Effekte einzelner Prädiktoren unter Kontrolle anderer Variablen zu schätzen – wichtig zur Vermeidung von Confounding (SAT-Beispiel).
5. **ANOVA-F-Tests** vergleichen geschachtelte Modelle und helfen bei der Modellwahl: einfache Modelle sind bevorzugt, solange sie nicht signifikant schlechter sind.