

Musterprüfung — Aufgaben 15–20

Schritt für Schritt zur Lösung — WDDA FS 2026

Ulrich Matter

Berner Fachhochschule — Datenmanagement und Datenanalyse

Worum geht es heute?

Wir lösen **sechs Prüfungsfragen** — von der beschreibenden Statistik bis zur Regression:

Fragen 15–17

Beschreiben

Boxplots zuordnen (15), Skalenniveau & Lagemass (16), Streuung, Form & Ausreisser (17).

Fragen 18–20

Schliessen & Modellieren

Bootstrap-CI für eine Anteilsdifferenz (18), Streudiagramme lesen (19), einfache Regression (20).

Roter Faden: **Erst die Daten verstehen** (Skalenniveau, Lage, Streuung), dann **Unsicherheit beziffern und Zusammenhänge modellieren**.

Mehrere Versionen pro Aufgabe

Wie in der **echten Prüfung** gibt es zu jeder Aufgabe **mehrere Versionen** desselben Typs — mit leicht **anderen Datensätzen bzw. Zahlen**, die beim Prüfungsantritt **zufällig** ausgewählt werden.

Sie bearbeiten dieselben Aufgaben wie hier — aber Ihre **konkreten Zahlen können abweichen**. **Keine Sorge**, wenn Ihre Ergebnisse nicht exakt mit den Werten auf diesen Folien übereinstimmen.

Nach diesen sechs Fragen können Sie:

1. einen **Boxplot lesen** und der passenden deskriptiven Statistik (Median, SD, Schiefe) zuordnen;
2. die **vier Skalenniveaus** unterscheiden und das passende **Lagemass** (Modus, Median, Mittelwert) wählen;
3. **Streuung** (SD, IQR) und **Form** (Schiefe) berechnen und **Ausreisser** mit der Tukey-Regel finden;
4. ein **Bootstrap-Konfidenzintervall** für eine Anteilsdifferenz bestimmen und auf Signifikanz prüfen;
5. ein **standardisiertes Streudiagramm** lesen und Korrelation, Lage und Streuung abschätzen;
6. eine **einfache lineare Regression** schätzen, R^2 und das Konfidenzintervall der Steigung interpretieren.

Frage 15 — Boxplots zuordnen

Aufgabentyp Zuordnung Boxplots: Ordnen Sie jedem Boxplot die passende deskriptive Statistik (Mean, SD, Median) zu.


Schlüssel

Ein Boxplot zeigt **Median**, **Streuung** und **Form** direkt — daraus lassen sich die drei Kennzahlen ablesen bzw. abschätzen.

Drei Leseregeln:

1. **Median** = die Linie in der Box — **direkt ablesbar**.
2. **SD** $\leftrightarrow$ Streuung: breitere Box + längere Whisker $\Rightarrow$ grössere Standardabweichung.
3. **Mean vs. Median** $\leftrightarrow$ Form (Schiefe): siehe nächste Folie.

Strategie: Form verrät Mean vs. Median



Vorgehen: (1) **Median** ablesen (oft schon fast eindeutig). (2) **Streuung** $\rightarrow$ SD.
(3) **Schiefte**: Median unten + Ausreisser rechts $\Rightarrow$ **Mean** $>$ **Median**; symmetrisch $\Rightarrow$ **Mean** $\approx$ **Median**.

Hinweis

Vollständige Musterlösung zu Frage 15: siehe **Moodle-Musterprüfung**.

Frage 16 — Skalenniveau & Lagemass

Datensatz Umfragedaten.xlsx — 100 Personen aus einer Marktforschungsumfrage. Vier Variablen:


1. Bestimme das **höchste Skalenniveau** von **Geschlecht, Bildung, Einkommen, Bewertung**.
2. Berechne für **Geschlecht, Bildung** und **Einkommen** das **angemessene Lagemass**.

Leitfrage

Warum darf man für die eine Variable einen Mittelwert bilden — und für die andere nur den häufigsten Wert nennen?

Kernkonzept: Die vier Skalenniveaus

Jede Variable trägt ein **Skalenniveau** — es sagt, welche Rechenoperationen sinnvoll sind.
Von wenig zu viel Information:



- **Beispiele:** Geschlecht (nom.), Schulnote (ord.), Temperatur in °C (int.), Einkommen/Gewicht (verh.)
- „Höchstes“ Skalenniveau = das informationsreichste, das die Variable noch zulässt.

Kernkonzept: Welches Lagemass ist erlaubt?

Das Skalenniveau bestimmt, welches **Lagemass** (Mass der zentralen Tendenz) sinnvoll ist:

Skalenniveau	Erlaubtes Lagemass	Warum
Nominal	Modus	nur „häufigster Wert“ zählbar
Ordinal	Median (+ Modus)	Rang $\Rightarrow$ Mitte bestimmbar
Intervall / Verhältnis	Mittelwert (+ Median, Modus)	Abstände $\Rightarrow$ Summe/Mittel ok

Merke

Faustregel: Ein höheres Skalenniveau erlaubt *alle* Lagemasse der niedrigeren — aber nie umgekehrt. Für **Geschlecht** gibt es keinen sinnvollen Mittelwert.

Schritt 1: Daten einlesen

```
library(readxl)
umfrage <- read_excel("Umfragedaten.xlsx")
str(umfrage)
```

```
tibble [100 x 4]
  $ Geschlecht: chr  "Divers" "Weiblich" "Weiblich" ...
  $ Bildung   : chr  "Bachelor" "Master" "Master" ...
  $ Einkommen : num  68600 64500 54700 66500 ...
  $ Bewertung : num  7 8 1 5 7 7 6 6 10 9 ...
```

Schon der Typ hilft: **chr** (Text) deutet auf nominal/ordinal, **num** auf intervall/verhältnis hin — aber **entscheidend ist die Bedeutung**, nicht der R-Typ.

Geschlecht: nominal → Modus


Divers, Männlich, Weiblich sind reine **Kategorien** ohne Rangordnung.

⇒ Skalenniveau: nominal

⇒ Lagemass: **Modus** (häufigste Kategorie)

```
table(umfrage$Geschlecht)
which.max(table(
  umfrage$Geschlecht))
```

Modus = **Weiblich** (60 von 100)




Bildung: ordinal → Median

Gymnasium < Bachelor < Master < Doktorat: es gibt eine **klare Ordnung**, aber die „Abstände“ sind nicht gleich.

⇒ Skalenniveau: **ordinal**

⇒ Lagemass: **Median** (mittlere Kategorie)

Mittelwert wäre **unsinnig** (was ist der Durchschnitt aus Gymnasium und Master?).



Bildung: den ordinalen Median finden

Der Median ist der Wert an Position 50,5 (Mittel aus 50. und 51. Wert) in der **geordneten** Reihe. Wir kumulieren die Häufigkeiten:

	Gymnasium	Bachelor	Master	Doktorat
Anzahl	23	44	21	12
kumuliert	23	67	88	100
Positionen	1–23	24–67	68–88	89–100

Die Positionen 50 *und* 51 fallen beide in **Bachelor** (Bereich 24–67).

⇒ Median = Bachelor

Einkommen: verhältnisskaliert → Mittelwert

Einkommen in CHF: **gleiche Abstände**
(1000 CHF sind überall 1000 CHF) und ein **echter Nullpunkt** (0 = kein Einkommen).

⇒ Skalenniveau: **verhältnis**


⇒ Lagemass: **Mittelwert**

```
round(mean(umfrage$Einkommen))
```

```
#> 83099
```

Mittelwert = 83 099 CHF

Hinweis: Die Verteilung ist rechtsschief, daher liegt der Mittelwert (83) über dem Median (72). Gefragt ist hier der **Mittelwert**.



Bewertung ist eine Skala von 1 bis 10 — eine **Rangbewertung**.

- Es gibt eine klare **Ordnung** (10 besser als 1)
- Aber: Ist der Abstand 1→2 gleich gross wie 9→10? Subjektiv **nicht garantiert**
- Höchstes *gesichertes* Niveau: **ordinal**
- Passendes Lagemass wäre der **Median** (= 6)

Achtung

Subjektive Ratings werden in der Praxis oft als metrisch *behandelt* — streng genommen sind sie **ordinal**. Im Zweifel das niedrigere, sichere Niveau angeben.

Frage 16 — Lösung auf einen Blick

Variable	Höchstes Skalenniveau	Angemessenes Lagemass
Geschlecht	nominal	Modus = Weiblich
Bildung	ordinal	Median = Bachelor
Einkommen	verhältnis (metrisch)	Mittelwert = 83 099 CHF
Bewertung	ordinal	(Median = 6)

Merke

Immer zuerst das **Skalenniveau** klären — es entscheidet, welche Kennzahl erlaubt ist.

Frage 17 — Streuung, Form & Ausreisser

Datensatz **Studentenleben.xlsx** — 80 Studierende und ihre Lebensstil-Daten.

Für die Variable **Lernstunden** (wöchentlich):

- **Lage**: Mittelwert, Median
- **Streuung**: Standardabweichung, Interquartilsabstand (IQR)
- **Form**: Schiefe, Verteilungsform
- **Ausreisser**: Anzahl gemäss Tukey-Regel ($1,5 \times \text{IQR}$)

Für die Variable **Verkehrsmittel**: der **Modus**.

Schritt 1: Daten einlesen & Überblick

```
library(readxl)
leben <- read_excel("Studentenleben.xlsx")
lern <- leben$Lernstunden
summary(lern)
```


Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.80	8.40	19.30	20.34	26.98	62.50

`summary()` liefert schon Min, Quartile, Median und Mittelwert — ein guter erster Überblick, bevor wir die einzelnen Kennzahlen sauber berechnen.

Schritt 2: Lage — Mittelwert & Median

```
mean(lern)    # 20.34  
median(lern)  # 19.30
```

- Mittelwert = 20,3
- Median = 19,3
- Mittelwert > Median — ein erster Hinweis auf Rechtsschiefe



Standardabweichung (SD)

$$s = \sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2}$$

- mittlere Abweichung vom *Mittelwert*
- reagiert **empfindlich** auf Ausreisser

Interquartilsabstand (IQR)

$$\text{IQR} = Q_3 - Q_1$$


- Breite der *mittleren* 50 %
- **robust** gegen Ausreisser

```
sd(lern)    # 14.0  
IQR(lern)   # 18.6    (= 26.975 - 8.4)
```

SD = 14,0 IQR = 18,6

Kernkonzept: Schiefe (Skewness)

Die **Schiefe** misst die **Asymmetrie** einer Verteilung:




- **rechtsschief** (> 0): langer Schwanz nach *rechts*, Mittelwert $>$ Median
- **linksschief** (< 0): langer Schwanz nach *links*, Mittelwert $<$ Median

Schritt 3: Schiefe & Verteilungsform

```
library(e1071)
skewness(lern)
#> 1.05
```

- Schiefe $\approx 1,05 > 0$
- langer Schwanz nach rechts (wenige Viel-Lerner)
- Mittelwert (20,3) $>$ Median (19,3)
bestätigt das
 $\Rightarrow$ rechtsschiefe Verteilung




Wichtig ist nicht die exakte Zahl, sondern das **Vorzeichen**: positiv $\Rightarrow$ rechtsschief.

Kernkonzept: Die Tukey-Ausreisserregel

Ein Wert gilt als **Ausreisser**, wenn er ausserhalb der „Zäune“ liegt, die $1,5 \times \text{IQR}$ über Q_3 bzw. unter Q_1 gesetzt werden:

$$\text{unterer Zaun} = Q_1 - 1,5 \cdot \text{IQR} \quad \text{oberer Zaun} = Q_3 + 1,5 \cdot \text{IQR}$$




Genau diese Regel zeichnet R automatisch im **Boxplot**.

Schritt 4: Ausreisser zählen

```
Q <- quantile(lern, c(.25,.75))
iqr <- Q[2] - Q[1]           # 18.6
zaun_oben <- Q[2] + 1.5*iqr # 54.8
zaun_unten<- Q[1] - 1.5*iqr # -19.5
sum(lern > zaun_oben |
     lern < zaun_unten)
#> 3
```

- oberer Zaun = 54,8, unterer = -19,5
- 3 Werte darüber: 57, 57, 62,5
⇒ 3 Ausreisser

Boxplot — Tukey-Ausreisserregel ($1.5 \times \text{IQR}$)




Verkehrsmittel: nominal → Modus

Verkehrsmittel ist **nominal** — also ist der **Modus** (häufigste Kategorie) das einzig sinnvolle Lagemass.

```
table(leben$Verkehrsmittel)
#> Auto Fahrrad   ÖV Zu Fuss
#>   25     11   36      8
```

Modus = **ÖV** (36 von 80)



Frage 17 — Lösung auf einen Blick

Kennzahl (Lernstunden)	Wert
Mittelwert	20,3
Median	19,3
Standardabweichung	14,0
Interquartilsabstand (IQR)	18,6
Schiefe	1,05
Verteilungsform	rechtsschief
Ausreisser (Tukey $1,5 \times \text{IQR}$)	3
Modus Verkehrsmittel	ÖV

Frage 18 — Bootstrap-CI für eine Anteilsdifferenz

Datensatz **ImpfabsichtUmfrage.xlsx** — 250 Personen, zufällig auf zwei Gruppen verteilt:


- **Behandlung**: sah ein informatives Aufklärungsvideo
- **Kontrolle**: sah ein neutrales Kontrollvideo

Impfabsicht ist binär kodiert (1 = ja, 0 = nein).

Gesucht ist die Differenz $\hat{p}_{\text{diff}} = \hat{p}_{\text{Behandlung}} - \hat{p}_{\text{Kontrolle}}$ und ein **95%-Bootstrap-Konfidenzintervall** (5000 Stichproben). Ist der Unterschied **signifikant**?

Kernkonzept: Warum Bootstrap für eine Differenz?

Wir haben *eine* Stichprobe und schätzen daraus *einen* Wert $\hat{p}_{\text{diff}}$. Aber wie sicher ist dieser?




Die **mittleren 95 %** der 5000 simulierten Differenzen bilden das Konfidenzintervall.
Enthält es die 0 nicht, ist der Unterschied signifikant.

Schritt 1: Anteile je Gruppe


```
library(readxl)
imp <- read_excel(
  "ImpfabsichtUmfrage.xlsx")
# Anteile je Gruppe
tapply(imp$Impfabsicht,
       imp$Gruppe, mean)
#> Behandlung  Kontrolle
#>      0.692      0.431
```

$$\hat{p}_{\text{diff}} = 0,692 - 0,431 = 0,26$$



Schritt 2: Bootstrap mit `mosaic::do()`

```
library(mosaic)
set.seed(2024)
pdiff <- function(d)
  mean(d$Impfabsicht[
    d$Gruppe=="Behandlung"]) -
  mean(d$Impfabsicht[
    d$Gruppe=="Kontrolle"])
boot <- do(5000) *
  pdiff(resample(imp))
quantile(boot$pdiff,
  c(.025, .975))
#>    0.14    0.38
```



Untere Grenze des 95%-CI	0,14
Obere Grenze des 95%-CI	0,38
Signifikant?	Ja

Merke


Das Intervall $[0,14; 0,38]$ enthält die **0 nicht** und liegt ganz im Positiven. Das Aufklärungsvideo erhöht die Impfbereitschaft also **statistisch signifikant** — um geschätzte 14 bis 38 Prozentpunkte.

Frage 19 — Ein Streudiagramm lesen


Die Aufgabe

Ein Streudiagramm ist gegeben. Welche Aussagen sind richtig? **Ohne Rechnen** – nur fundiert *abschätzen*:

- a. $|r| \geq 0,8$
- b. Für $X = -0,8$ erwartet man $Y \approx 1,9$
- c. Das Streudiagramm ist standardisiert
- d. Mittelwert von X ist ungefähr 0
- e. Standardabweichung von X ist mindestens 5



Kernkonzept: Was man aus den Achsen abliest



Achsenbereiche verraten Lage & Streuung:

- X läuft von ≈ -15 bis $+12$, Wolke um 0 zentriert $\Rightarrow$ Mittelwert ≈ 0
- Spannweite ≈ 27 ; Faustregel $SD \approx \text{Spannweite}/4 \Rightarrow SD_X \approx 5-6$
- Y läuft nur von $-2,5$ bis $+2,5 \Rightarrow$ sieht standardisiert aus ($\bar{y} \approx 0$, $s_y \approx 1$)
- X ist **nicht** standardisiert ($SD \gg 1$)

Frage 19 — die Aussagen einzeln prüfen

Aussage	Beurteilung
a. $ r \geq 0,8$	richtig: enge, klar steigende Wolke
b. $X = -0,8 \Rightarrow Y \approx 1,9$	falsch: bei $X \approx 0$ ist $Y \approx 0$, nicht 1,9
c. standardisiert	falsch: nur Y, X hat $SD \approx 5$
d. $\bar{X} \approx 0$	richtig: Wolke um 0 zentriert
e. $SD_X \geq 5$	richtig: Spannweite ≈ 27

Merke

Richtige Antworten: **a, d, e**. Schlüssel: Achsenbereiche zeigen Lage und Streuung, der Punkt (0,0) die Regressionsmitte.

Frage 20 — Einfache lineare Regression

Datensatz **Immobilienpreise.xlsx** — 120 verkaufte Einfamilienhäuser.

- **Quadratmeter**: Wohnfläche in m^2
- **Preis_kCHF**: Verkaufspreis in 1000 CHF

Einfache lineare Regression **Preis_kCHF** $\sim$ **Quadratmeter**. Gesucht:


- **Steigung** (2 Dezimalstellen) und R^2 (3 Dezimalstellen)
- **95%-Konfidenzintervall** für die Steigung
- Ist die Steigung **signifikant** von Null verschieden ($\alpha = 0,05$)?

Schritt 1: Modell schätzen

```
imm <- read_excel(  
  "Immobilienpreise.xlsx")  
mod <- lm(Preis_kCHF ~  
          Quadratmeter, data = imm)  
summary(mod)
```

	Estimate	Std.Err	t value
(Intercept)	-12.7338	19.20	-0.66
Quadratmeter	4.1807	0.102	40.8

Multiple R-squared: 0.9339



Steigung = 4,18 $R^2 = 0,934$ (pro m² rund 4180 CHF mehr)

Schritt 2: Konfidenzintervall & Signifikanz

```
confint(mod, "Quadratmeter")           # 95%-CI der Steigung
#>                2.5 %    97.5 %
#> Quadratmeter  3.978    4.384
```

- 95%-CI der Steigung: [3,98; 4,38]
- das Intervall liegt klar **über 0**
- $t = 40,8$, $p < 0,001$

Merke

Da das CI die 0 nicht enthält (und $p < 0,05$), ist die Steigung **signifikant** – Wohnfläche erklärt den Preis sehr deutlich.

Frage 20 — Lösung auf einen Blick

Kennzahl	Wert
Steigung der Regressionsgeraden	4,18
Bestimmtheitsmass R^2	0,934
95%-CI Steigung – untere Grenze	3,98
95%-CI Steigung – obere Grenze	4,38
Signifikant von Null verschieden?	Ja

Zusammenfassung

Fragen 15–17

Beschreiben

Boxplots lesen; Skalenniveau $\rightarrow$ Lagemass; Lage, Streuung (SD/I-QR) und Form (Schiefe, Tukey-Ausreisser).

Frage 18

Schliessen

Bootstrap-CI für eine Anteilsdifferenz. Enthält das CI die 0 nicht $\Rightarrow$ signifikant.

Fragen 19 & 20

Zusammenhänge

Streudiagramm abschätzen (Korrelation, Lage, Streuung) und Regression schätzen (R^2 , CI der Steigung).

Roter Faden

Erst **beschreiben** (Skalenniveau, Lage, Streuung, Form), dann **Unsicherheit beziffern** (Bootstrap) und **Zusammenhänge modellieren** (Regression).

Fragen?