

Regression Schritt für Schritt

Drei Übungen aus den Serien 5, 6 und 7 — WDDA FS 2026

Ulrich Matter

Berner Fachhochschule — Datenmanagement und Datenanalyse



Bern University
of Applied Sciences

Worum geht es heute?

Wir lösen **drei ausgewählte Übungen** — und lernen dabei die Kernideen der Regression kennen:

Serie 5

Einfache Regression

Diamantringe: eine Gerade durch die Daten — und ein *Schnäppchen-Test*.

Serie 6

Multiple Regression

Download: Was passiert, wenn zwei Prädiktoren fast *das-selbe* messen?

Serie 7

Inferenz

Advertising: Wie *sicher* sind unsere Schätzungen und Prognosen?

Roter Faden: Gerade anpassen → mehrere Prädiktoren → Unsicherheit ehrlich beziffern.

Nach diesen drei Übungen können Sie:

1. eine **einfache lineare Regression** in R aufstellen und Achsenabschnitt, Steigung sowie R^2 /RSE interpretieren;
2. ein **Prognoseintervall** nutzen, um eine konkrete Entscheidung zu treffen;
3. **marginale** und **partielle** Steigungen unterscheiden und **Multikollinearität** erkennen;
4. **Konfidenzintervalle** klassisch und per **Bootstrap** berechnen und vergleichen;
5. mit **t-Test** und **F-Test** entscheiden, welche Prädiktoren ins Modell gehören;
6. **Konfidenz-** und **Prognoseintervall** auseinanderhalten.

Serie 5 — Einfache lineare Regression

Die Aufgabe: Diamantringe

Datensatz Diamonds Rings (48 Ringe): Gewicht in Karat, Listenpreis in Singapur-Dollar (SGD).

Wir wollen:

1. den Zusammenhang **Preis** $\sim$ **Gewicht** modellieren,
2. Achsenabschnitt, Steigung und Modellgüte interpretieren,
3. den Preisunterschied zwischen 0.25 und 0.35 ct schätzen,
4. entscheiden: Ist ein Ring mit **0.18 ct für 325 SGD** ein **Schnäppchen**?

Leitfrage

Wie zieht man die *beste* Gerade durch eine Punktwolke — und was heisst „beste“?

Kernkonzept: Was ist eine lineare Regression?

Wir beschreiben den Preis als **Gerade** im Gewicht:

$$\hat{y} = \underbrace{b_0}_{\text{Achsenabschnitt}} + \underbrace{b_1}_{\text{Steigung}} \cdot x$$

- x = Gewicht (Karat), $\hat{y}$ = geschätzter Preis
- b_0 : Modellpreis bei $x = 0$
- b_1 : **Mehrpri**s pro zusätzlichem Karat
- Die Abweichung jedes Punkts von der Geraden heisst **Residuum**
 $e_i = y_i - \hat{y}_i$
- R berechnet b_0, b_1 mit einer Zeile:
`lm( )`

Merke


Korrelation sagt „es gibt einen Zusammenhang“. Regression sagt **wie stark** und erlaubt **Prognosen**.

Schritt 1-2: Daten einlesen und ansehen


```
library(readxl)
diamonds <- read_excel(
  "WDDA_05.xlsx",
  sheet = "Diamonds Rings")
names(diamonds) <- c("weight", "price")

plot(diamonds$weight, diamonds$price)
```

Immer zuerst **plotten**: Ist der Zusammenhang überhaupt ungefähr linear? Hier: ja, klar steigend.



Kernkonzept: Die Methode der kleinsten Quadrate



R wählt b_0, b_1 so, dass die **Summe der quadrierten Residuen** minimal wird:

$$\min_{b_0, b_1} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \min \sum_i e_i^2$$

- rote Linien = Residuen e_i
- Quadrieren $\Rightarrow$ grosse Abweichungen zählen stärker
- Ergebnis: **eine eindeutige** beste Gerade

Schritt 3: Modell schätzen mit `lm()`

```
mod_dr <- lm(price ~ weight, data = diamonds)
summary(mod_dr)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-259.63	17.32	-14.99	<2e-16	***
weight	3721.02	81.79	45.50	<2e-16	***

Residual standard error: 31.84 on 46 degrees of freedom

Multiple R-squared: 0.9783

$$\hat{\text{price}} = -259,63 + 3721,02 \cdot \text{weight}$$

Schritt 3: Was bedeuten die Koeffizienten?

$$\hat{\text{price}} = \underbrace{-259,63}_{b_0} + \underbrace{3721,02}_{b_1} \cdot \text{weight}$$

Steigung $b_1 = 3721 \text{ SGD/ct}$

- Jedes zusätzliche Karat $\rightarrow$ rund **3721 SGD** mehr
- das ist die zentrale, sinnvolle Zahl

Achsenabschnitt $b_0 = -259 \text{ SGD}$

- rechnerischer Preis bei 0 ct — ein **negativer** Preis
- **nicht sinnvoll interpretierbar**: 0 ct liegt weit ausserhalb der Daten (0.12–0.35 ct)

b_1 ist die zentrale Zahl — mit b_0 ist Vorsicht geboten (nächste Folie).

Schritt 3: Vorsicht beim Achsenabschnitt

$b_0 = -259$ SGD ist der Modellwert bei **0 Karat** — ein **negativer Preis**. Kein Widerspruch:

Warum?

- Daten nur von **0.12–0.35 ct**
- $x = 0$ liegt weit ausserhalb $\Rightarrow$
Extrapolation

Was zählt?

- die **Steigung** b_1
- Prognosen *innerhalb* der Daten


Achtung

b_0 nie blind interpretieren — $x = 0$ ist reine Extrapolation.

Kernkonzept: Wie gut ist das Modell? (R^2 , RSE)

Idee: Zerlege die gesamte Streuung der Preise (TSS) in einen *erklärten* und einen *unerklärten* Teil (RSS).

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\sum e_i^2}{\sum (y_i - \bar{y})^2} = 1 - \frac{46\,636}{2\,145\,232} = 0,978$$



$R^2 = 0,978$: Gewicht erklärt 97,8 % der Preisstreuung.

RSE = 31,84 **SGD**: typischer Prognosefehler — so weit liegen Preise im Schnitt von der Geraden.

Schritt 4: Preisunterschied 0.25 → 0.35 ct

Eine Steigung lässt sich direkt in eine **Differenz** übersetzen — b_0 fällt weg:

$$\Delta \hat{\text{price}} = b_1 \cdot (0,35 - 0,25) = 3721,02 \cdot 0,10 \approx 372 \text{ SGD}$$

```
coef(mod_dr)["weight"] * (0.35 - 0.25)
#> 372.1
```

Merke

Für *Unterschiede* brauchen wir nur die Steigung — ein häufiger Prüfungstrick.

Kernkonzept: Das Prognoseintervall

Eine Punktprognose ist eine *einzige* Zahl — aber jeder echte Ring streut um die Gerade. Das **Prognoseintervall (PI)** gibt den Bereich an, in dem ein **einzelner neuer** Ring mit 95 % liegt und berücksichtigt damit die Streuung **einzelner** Beobachtungen:

$$\hat{y} \pm t_{0,975} \cdot \underbrace{\text{RSE} \cdot \sqrt{1 + \frac{1}{n} + \dots}}_{\text{Streuung Einzelwert}}$$

In R: `predict(..., interval = "prediction")`.

Merke

Liegt ein Angebot *unter* der PI-Untergrenze, ist es ungewöhnlich günstig — ein **Schnäppchen**.


Schritt 5: Der Schnäppchen-Check

```
predict(mod_dr,  
  data.frame(weight = 0.18),  
  interval = "prediction",  
  level = 0.95)
```

fit	lwr	upr
410.2	345.3	475.0

Angebot: 325 SGD < 345,3 (Untergrenze)

⇒ Schnäppchen!



- `lm(price ~ weight)` liefert die kleinste-Quadrate-Gerade in einer Zeile
- **Steigung** = Mehrpreis pro Einheit; **Achsenabschnitt** oft nicht sinnvoll interpretierbar
- R^2 misst den erklärten Anteil, **RSE** den typischen Fehler
- das **Prognoseintervall** macht aus dem Modell eine konkrete Entscheidung (Schnäppchen ja/nein)

Übergang zu Serie 6

Bisher: **ein** Prädiktor. Was, wenn wir **mehrere** haben — und diese sich gegenseitig ins Gehege kommen?

Serie 6 — Multiple Regression

Die Aufgabe: Download-Zeiten

Datensatz Download (80 Übertragungen): Übertragungszeit (s), Dateigrösse (MB) und *Stunden nach 8:00 Uhr*.

Wir erweitern das einfache Modell aus Serie 5:

$$\text{time} = b_0 + b_1 \cdot \text{size} \quad \longrightarrow \quad \text{time} = b_0 + b_1 \cdot \text{size} + b_2 \cdot \text{hours}$$

- Was passiert mit der Steigung von **size**, wenn **hours** dazukommt?
- Lohnt sich der zweite Prädiktor überhaupt?

Leitfrage

Zwei Prädiktoren, die fast *dasselbe* messen — Hilfe oder Problem?

Marginale Steigung

(einfache Regression $\text{time} \sim \text{size}$)

- Effekt von **size** **allein**
- ignoriert alle anderen Variablen

Partielle Steigung

(multiple Regression)

- Effekt von **size**, **wenn hours konstant gehalten wird**
- „bei sonst gleichen Bedingungen“

Merke

Sind die Prädiktoren **unkorreliert**, sind marginale und partielle Steigung praktisch gleich.


Sind sie **stark korreliert**, können sie sich dramatisch unterscheiden.

Schritt 1: Die Prädiktoren ansehen

```
cor(download$size_mb,  
     download$hours_after_8)  
#> 0.988
```

Die Dateigrösse und „Stunden nach 8 Uhr“ sind mit $r = 0,99$ fast **perfekt korreliert** — sie tragen kaum eigene Information.

Frühwarnsignal für Multikollinearität!




Schritt 2–3: Beide Modelle schätzen

```
# marginal: nur size
lm(time_sec ~ size_mb, data = download)
# partiell: size + hours
lm(time_sec ~ size_mb + hours_after_8, data = download)
```

Steigung size	Schätzung	Std.-Fehler	Bedeutung
marginal (allein)	0,313	0,028	präzise
partiell (mit hours)	0,324	0,180	6,4× ungenauer

Die Schätzung ändert sich kaum — aber der **Standardfehler explodiert**.



Wenn zwei Prädiktoren fast dasselbe messen, kann das Modell ihre Effekte **nicht sauber trennen**:

- Schätzungen werden **instabil** (riesige Standardfehler)
- Koeffizienten bekommen oft **unsinnige Vorzeichen**
- Diagnose: **VIF** (Variance Inflation Factor)

Faustregel: $VIF > 10$ ist kritisch. Hier: **$VIF = 42$** .

Schritt 4: Diagnose — bringt hours etwas?

```
summary(mod_multi)$coef      # Auszug
#>           Estimate Std. Error t value Pr(>|t|)
#> size_mb           0.324     0.180   1.80   0.076
#> hours_after_8      -0.186     3.162  -0.06   0.953
library(car); vif(mod_multi)
#> size_mb  hours_after_8
#>    42.2         42.2
```

- **hours**-Koeffizient **negativ und völlig insignifikant** ($p = 0,95$) — inhaltlich unsinnig
- R^2 : 0,625 (einfach) vs. 0,625 (multipel) — **kein Gewinn**
- **Adjusted R^2 sinkt** sogar ($0,620 \rightarrow 0,615$)

- Multiple Regression schätzt **partielle** Effekte: „bei sonst gleichen Bedingungen“
- Stark korrelierte Prädiktoren ($r = 0,99$) verursachen **Multikollinearität**
- Symptome: explodierende Standardfehler, unsinnige Vorzeichen, $VIF \gg 10$
- Mehr Variablen $\neq$ besseres Modell — **adjusted** R^2 und F-Test entscheiden

Übergang zu Serie 7

Der explodierende Standardfehler ist genau das Thema von Serie 7: **Wie sicher sind unsere Koeffizienten überhaupt?**

Serie 7 – Inferenz in der Regression

Datensatz Advertising (200 Märkte): Umsatz (**sales**) in Abhängigkeit von Werbe-Budgets für **TV, radio, newspaper**.

Wir fragen nicht mehr nur „*wie gross* ist der Effekt?“, sondern:

1. Wie **präzise** ist die geschätzte TV-Steigung? (klassisches vs. Bootstrap-Konfidenzintervall)
2. Welche Prädiktoren sind **statistisch signifikant**? (t-Test, F-Test)
3. Wie unterscheiden sich **Konfidenz-** und **Prognoseintervall**?

Kernkonzept: Von der Schätzung zur Unsicherheit

Unsere Daten sind nur **eine Stichprobe**. Mit anderen 200 Märkten bekämen wir leicht andere Koeffizienten.

Konfidenzintervall

Bereich, in dem der **wahre** Koeffizient mit 95 % Wahrscheinlichkeit liegt.

Signifikanztest

Ist der Effekt **unterscheidbar von Null**? Kleines $p \Rightarrow$ ja.

Merke

Inferenz = von der Stichprobe auf die **Grundgesamtheit** schliessen — mit ehrlicher Angabe der Unsicherheit.


Schritt 1–2: Modell und klassisches KI

```
mod_tv <- lm(sales ~ TV,  
             data = Advertising)  
confint(mod_tv)
```

	2.5 %	97.5 %
(Intercept)	6.1297	7.9355
TV	0.0422	0.0528


$\hat{b}_1 = 0,0475$: pro zusätzlichem \$1000
TV-Budget rund **47,5** mehr verkaufte
Einheiten. Hoch signifikant ($p \approx 10^{-42}$).

95 %-KI für TV: [0,0422, 0,0528] — klar oberhalb von 0.



Kernkonzept: Der Bootstrap



Idee: Statt eine Formel zu glauben, simulieren wir die Unsicherheit aus den Daten selbst.



Die **Streuung der 5000 Schätzungen** ist direkt das Konfidenzintervall — ganz ohne Verteilungsannahme.

Schritt 3: Bootstrap-KI und Vergleich

```
library(mosaic)
set.seed(123)
simcoef <- do(5000) *
  coef(lm(sales ~ TV,
    data = resample(Advertising)))
quantile(simcoef$TV,
  c(0.025, 0.975))
#> 0.0419 0.0531
```



95 %-KI für TV	untere	obere
klassisch (confint)	0,0422	0,0528
Bootstrap (5000)	0,0419	0,0531



Praktisch identisch — die klassischen Annahmen passen hier gut.

Schritt 4: Multiple Regression — alle Kanäle

```
mod_full <- lm(sales ~ TV + radio + newspaper, data = Advertising)
summary(mod_full)$coef
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.93889	0.31191	9.422	< 2e-16 ***
TV	0.04576	0.00139	32.809	< 2e-16 ***
radio	0.18853	0.00861	21.893	< 2e-16 ***
newspaper	-0.00104	0.00587	-0.177	0.860

TV und radio hoch signifikant — newspaper mit $p = 0,86$ nicht von Null unterscheidbar.

Kernkonzept: t-Test vs. F-Test

t-Test

Prüft **einen einzelnen** Koeffizienten:

$$H_0 : \beta_j = 0.$$

Steht in jeder Zeile der **summary**-Ausgabe (Spalte **Pr(> | t |)**).

F-Test

Prüft **mehrere** Koeffizienten gemeinsam, bzw. vergleicht zwei **geschachtelte** Modelle:

„Bringt die Zusatzvariable als Gruppe etwas?“

Merke

Für „lohnt sich **newspaper**?“ vergleichen wir das Modell *mit* und *ohne newspaper* per F-Test (anova).

Schritt 5: Modellvergleich per F-Test

```
mod_red <- lm(sales ~ TV + radio, data = Advertising)
anova(mod_red, mod_full)
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	197	556.91				
2	196	556.83	1	0.08872	0.0312	0.860

- $F = 0,03$, $p = 0,86 \Rightarrow$ **newspaper** liefert **keinen** signifikanten Zusatzbeitrag
- Der p -Wert stimmt mit dem t-Test überein (bei *einer* Variable identisch)
- **Entscheidung:** **newspaper** entfernen — einfacheres Modell bevorzugen

Kernkonzept: Konfidenz- vs. Prognoseintervall

Beide drehen sich um die Frage „Wie viel **sales** bei TV=200, radio=30?“ — aber sie beantworten **verschiedene** Fragen:

Konfidenzintervall (CI)

Wo liegt der **Mittelwert** der Sales über *viele* Märkte mit diesen Budgets?
→ **eng**

Prognoseintervall (PI)


Wo liegt **ein einzelner, neuer** Markt?
→ **breiter** (zusätzliche Einzel-Streuung)

Das PI enthält das CI *immer* — es trägt eine zusätzliche Unsicherheitsquelle.

Schritt 6: CI und PI berechnen

```
nv <- data.frame(TV = 200, radio = 30)
predict(mod_red, nv,
        interval = "confidence")
#>      fit      lwr      upr
#> 17.71  17.42  18.01
predict(mod_red, nv,
        interval = "prediction")
#>      fit      lwr      upr
#> 17.71  14.38  21.04
```

CI-Breite $\approx 0,6$, PI-Breite $\approx 6,7$ — gut $10\times$ breiter.



Zusammenfassung

Die drei grossen Ideen

Serie 5

Anpassen & nutzen

Kleinste Quadrate, b_0/b_1 , R^2/RSE — und das **Prognoseintervall** für echte Entscheidungen.

Serie 6

Mehrere Prädiktoren

partielle Steigung „bei sonst Gleichem“ — und die Gefahr der **Multi-kollinearität**.

Serie 7

Unsicherheit

KI (klassisch & **Bootstrap**), t-/F-Test, CI vs. PI — **wie sicher** sind wir?

Roter Faden

Ein Modell ist erst vollständig, wenn wir nicht nur die **Punktschätzung** kennen, sondern auch ihre **Unsicherheit** ehrlich beziffern.

Fragen?